




Deep reinforcement learning for de novo drug design

A ReLeaSe method execution on a Docker Environment

Relatori:


Ivan Buccella

Matteo Maiorano



01

Introduction



L'Intelligenza Artificiale




Rivoluzione della medicina



Deep Reinforcement
Learning (DRL)

Nella scoperta di farmaci,
l'obiettivo è di formulare
un'ipotesi su come sintetizzare
nuovi composti o selezionarli
dalle librerie chimiche
disponibili.

Librerie basate su SAR data



Generating Focused Molecule Libraries for Drug Discovery with Recurrent Neural Networks

Marwin H. S. Segler^{†*}, Thierry Kogej[‡], Christian Tyrchan[§], and Mark P. Waller^{¶||}

View Author Information ▾

Cite this: *ACS Cent. Sci.* 2018, 4, 1, 120–131

Publication Date: December 28, 2017 ▾

<https://doi.org/10.1021/acscentsci.7b00512>

Copyright © 2017 American Chemical Society

[RIGHTS & PERMISSIONS](#) 

Article Views

33214

Altmetric

39

Citations

600

[LEARN ABOUT THESE METRICS](#)

Share Add to Export



ACS Central Science

 PDF (2 MB)

 Supporting Info (2) »

SUBJECTS: Drug discovery, Molecular modeling, Molecular structure, Molecules, Neural networks

- Le RNN possono essere addestrate come modelli generativi per le strutture molecolari
- Le proprietà delle molecole generate si correlano molto bene
- Genera nuove molecole per il de novo drug design



Molecular de-novo design through deep reinforcement learning

[Marcus Olivecrona](#) , [Thomas Blaschke](#), [Ola Engkvist](#) & [Hongming Chen](#)

[Journal of Cheminformatics](#) **9**, Article number: 48 (2017) | [Cite this article](#)

28k Accesses | **427** Citations | **46** Altmetric | [Metrics](#)



- Generazione di composti che si prevede siano attivi contro un bersaglio biologico
- Contro il recettore della **dopamina di tipo 2** genera strutture di cui si prevede che oltre il 95% sia attivo
 - inclusi attivi confermati sperimentalmente
 - non inclusi né nel modello generativo né nel modello predittivo





Le structure-activity relationship (SAR)

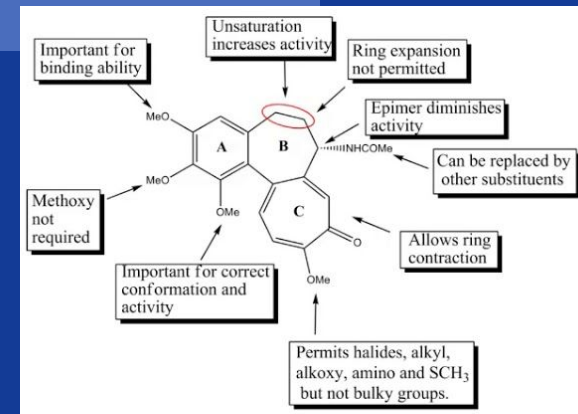
Tecnica utilizzata in chimica farmaceutica e biologica per prevedere l'attività di un composto chimico basandosi sulla sua struttura molecolare.

Utilizzo



sintetizzare nuovi composti con attività biologica desiderata

capire come una modifica strutturale può influire sull'attività di un composto esistente





Enorme quantitativo di sostanze chimiche sinteticamente fattibili.
Impossibile:

- l'esaminazione sistematica
- la verifica attraverso la costruzione della stessa
- valutazione di ogni singolo composto

Molto utili le Deep Neural Networks (DNN).





Apprendimento dati tramite algoritmi
Elaborare grandi quantità di dati

Deep Learning




Agente interagisce con il suo ambiente
Massimizzare ricompensa
Trial and Error

Reinforcement Learning (RL)



**Deep Reinforcement Learning
(DRL)**


Deep Neural Networks to learn RL Policy





Deep Neural Network (DNN)


- Composta da neuroni
- Imita il modo in cui il cervello elabora i dati
- Apprendere automaticamente i modelli presenti nei dati di input





Recurrent Neural Network (RNN)


- Composta da neuroni
- Struttura a loop
- Elaborazione sequenziale, ma
- Informazioni precedenti influiscono sull'elaborazione attuale
- Utilizza uno strato Long Short-Term Memory





Long Short-Term Memory (LSTM)

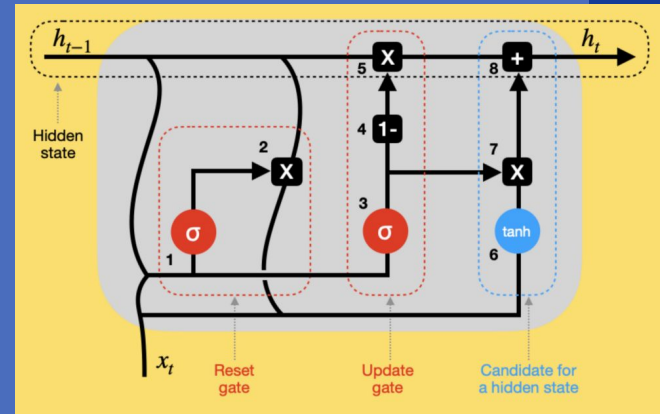
- Memorizza le informazioni a lungo termine.
- Controlla quali informazioni vengono mantenute e dimenticate,
- Elaborazione di sequenze di input di lunga durata.





Gated Recurring Unit

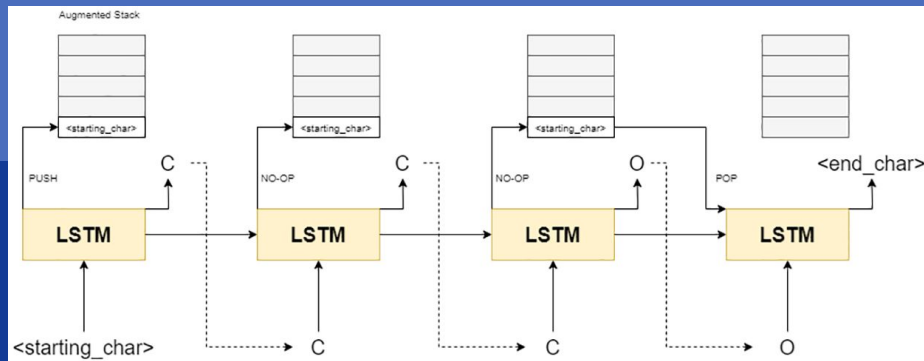
- Un meccanismo di gating nelle RNN
- Porte per controllare il flusso di informazioni all'interno e all'esterno dell'hidden state
- Impara quali parti della sequenza sono più efficaci






Stack-Augmented Recurrent Neural Network (Stack-RNN)

- Struttura di dati a stack per memorizzare e elaborare sequenze di dati
- Mantenere una gerarchia di informazioni
- Ideale per dati con una struttura ad albero o gerarchica
- Stato dello stack viene aggiornato ad ogni passo temporale



02


Background





Simplified Molecular Input Line Entry System (SMILES)


- Descrivere la struttura di una molecola con una stringa ASCII
- Atomi: simbolo chimico chiuso tra parentesi quadre `[Au]` ORO
- Legame: uno tra i simboli `.` `-` `=` `#` `$` `:` `/` `\`
- Anelli: etichetta numerica, rotti in punto arbitrario
- Rami: descritti con parentesi `CCC(=O)O` ACIDO PROPIONICO
- Stringhe contenute in file con estensione `.smi`





Melting Point (T_m)


- temperatura alla quale un solido passa allo stato liquido
- può influire sulla stabilità e la conservazione di un composto
- può influire sulla sua sicurezza e biodisponibilità





Inhibitory concentration (IC) & Half maximal IC (IC₅₀)


- IC misura dell'efficacia di un composto chimico nell'inibire l'attività di un particolare bersaglio biologico
- IC₅₀ = quantità di sostanza inibitoria (ad es. farmaco) necessaria per inibire del 50% un bersaglio biologico
- pIC₅₀ = logaritmo negativo di IC₅₀
- pIC₅₀ usato per valutare l'efficacia di un farmaco
- Più alta è la pIC₅₀ di un composto, maggiore è la sua attività biologica





Coefficiente di ripartizione (logP)

- Misura quanto di un soluto si dissolve nella porzione di acqua rispetto a una porzione organica
- Aiuta a determinare se un composto sarà più solubile in grasso o in acqua
- Proprietà di un composto chimico per prevedere la sua tossicità o l'attività biologica






Regola di Lipinski

- Insieme di criteri che vengono utilizzati per valutare la "farmacocinetica orale" di una sostanza chimica
 - la capacità di un composto chimico di essere assorbito e distribuito nel corpo attraverso l'ingestione orale
- Sviluppata per identificare composti chimici idonei per il trattamento farmacologico degli esseri umani attraverso l'ingestione orale



03

ReLeaSe



Deep reinforcement learning for de novo drug design

MARIYA POPOVA, OLEXANDR ISAYEV , AND ALEXANDER TROPSHA [Authors Info & Affiliations](#)

SCIENCE ADVANCES • 25 Jul 2018 • Vol 4, Issue 7 • DOI: 10.1126/sciadv.aap7885

15,649



Reinforcement Learning for Structural Evolution

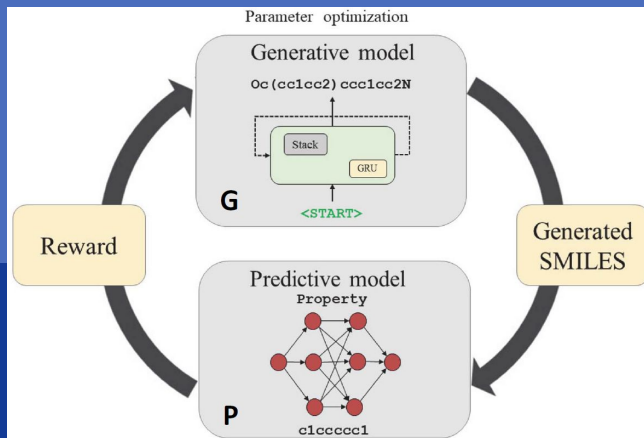
- Metodo per generare composti chimici con proprietà fisiche, chimiche e/o bioattive desiderate basate sul DRL
- Prevedere diverse proprietà descritte in precedenza come $\log P$, T_m e pIC_{50}
- Può imparare a selezionare le molecole più promettenti per lo sviluppo di nuovi farmaci!!!





Training Process

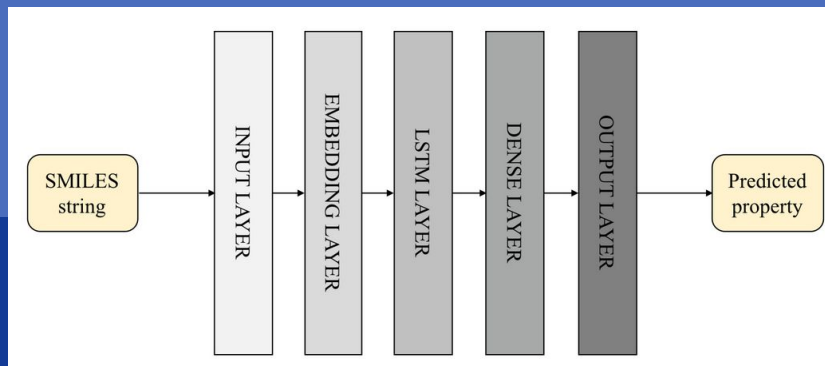
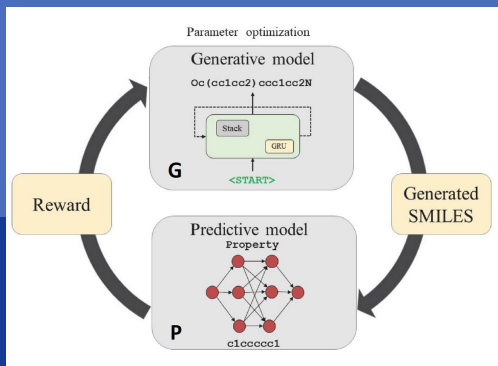
- Viene costruito il generative model, poi
- entrambi i modelli, generative e predictive, sono combinati in un unico sistema di Reinforcement Learning





Predictive Model

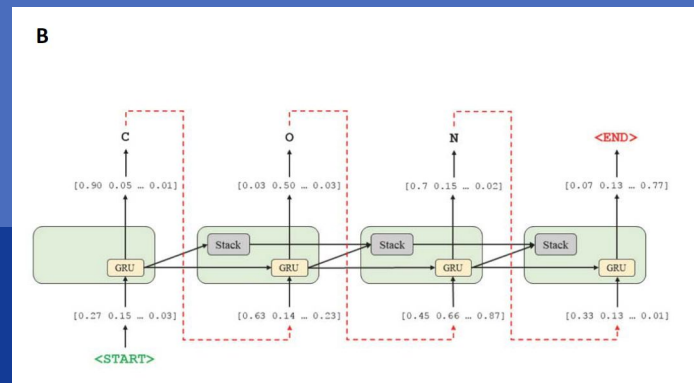
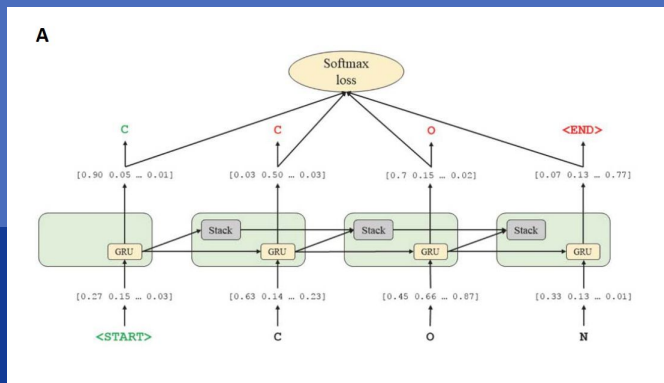
- Stima delle proprietà fisiche, chimiche o biologiche delle molecole
- Riceve in input una SMILES string
- Restituisce in output la predicted property (logP)





Generative Model

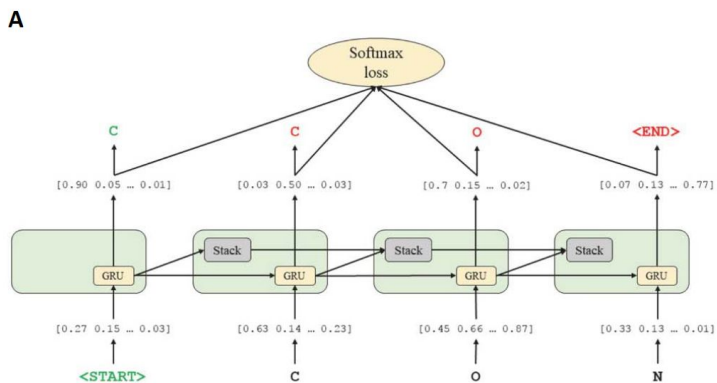
- Utilizzo di Stack-RNN
- Apprendere regole nascoste per formare sequenze di lettere che corrispondono a stringhe SMILES legittime.
- Due modalità: training (A) e generating (B)





Fase 1 - Generative Model - Training

- Prende un prefisso corrente del training object e prevede la distribuzione di probabilità del carattere successivo
- Il carattere successivo viene campionato da questa distribuzione di probabilità prevista
- Funzione poi confronta la previsione con la correttezza della stringa SMILES

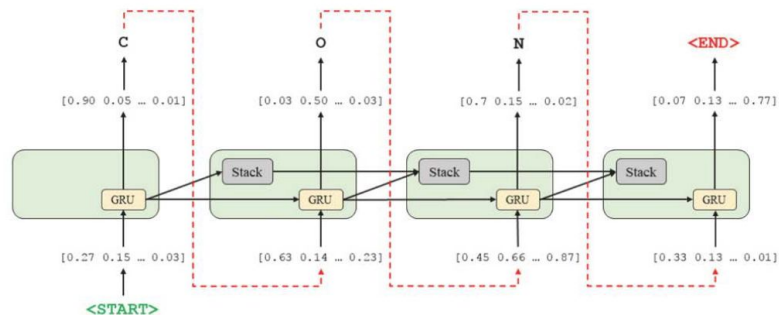




Fase 1 - Generative Model - Generating

- Prende un prefisso di sequenze già generate
- Prevede la distribuzione di probabilità del carattere successivo
- La campiona da questa distribuzione prevista

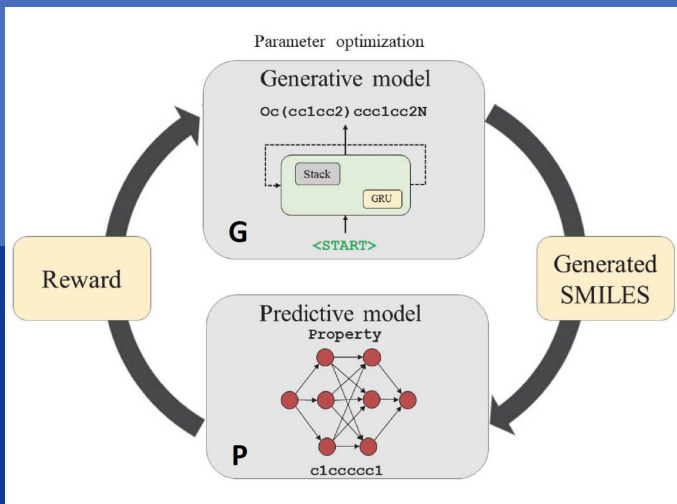
B





Fase 2 - Reinforcement Learning

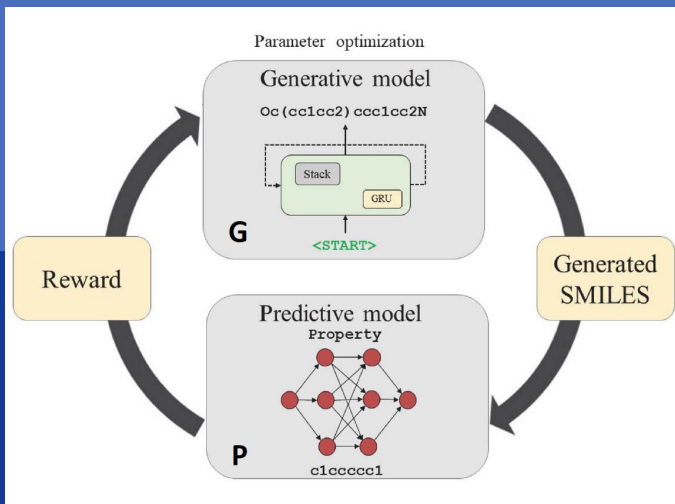
- Reward: funzione della proprietà numerica calcolata dal predictive model
- Generative Model: viene addestrato per massimizzare la ricompensa attesa





Fase 2 - Generative Model

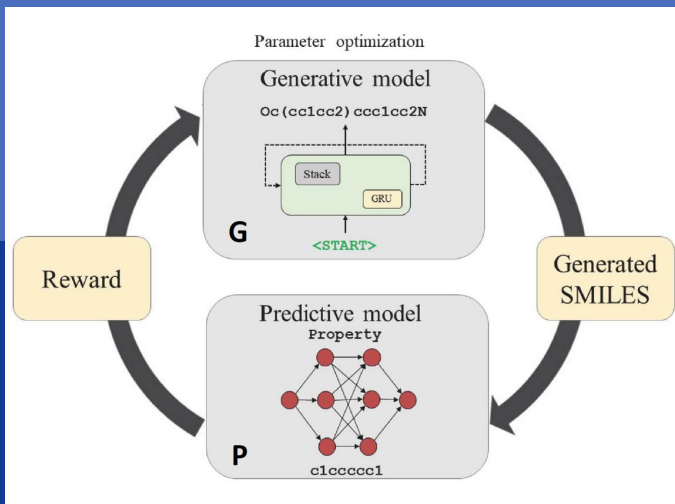
- Ruolo di agente
- spazio delle azioni è rappresentato dall'alfabeto della notazione SMILES
- spazio degli stati è rappresentato da tutte le possibili stringhe di questo alfabeto





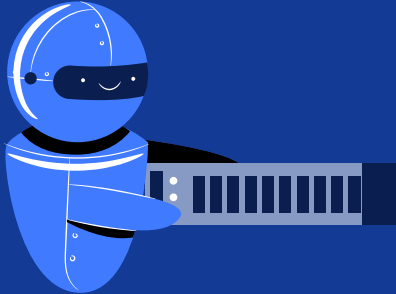
Fase 2 - Predictive Model

- Stima il comportamento dell'agente
- Assegna una ricompensa (reward) numerica ad ogni molecola generata



04

The Execution





ReLeaSe

Produzione di molecole con valori di logP all'interno di drug-like regions secondo la regola di Lipinsky.

Policy Gradient Algorithm con una funzione di reward personalizzata





Il generator produce una nuova stringa SMILES valutata dal predictor.

Sulla base della previsione ottenuta e dell'obiettivo, viene assegnato un valore di ricompensa numerico e vengono aggiornati i parametri del generator utilizzando un policy gradient algorithm.

Il policy gradient loss è definito come segue:

$$L(S|\theta) = -\frac{1}{n} \sum_{i=1}^{|S|} \sum_{j=1}^{length(s_i)} R_i \cdot \gamma^j \cdot \log p(s_i | s_0 \dots s_{i-1} \theta),$$





Prerequisites

Hardware

- Linux OS oppure WSL2 su Windows 10 (o superiore) macchina.
- NVIDIA GPU, compatibile con CUDA 11.3.





Prerequisites

Software

- Docker and Docker Compose (Application containers engine)
<https://www.docker.com>
- Il supporto GPU è abilitato sulla macchina
<https://docs.docker.com/compose/gpu-support/>





Prerequisites

Nvidia Container Toolkit

<https://docs.nvidia.com/datacenter/cloud-native/container-toolkit/install-guide.html#install-guide>

N.B necessario installare il CUDA Toolkit sul sistema host.

N.B necessario installare i driver NVIDIA sul sistema





The Dockerfile

Image Nvidia/cuda

Installazione di Miniconda

Creazione della release
environment

Installazione dei pacchetti
conda e pip richiesti

Clone Repository ReLeaSe

```
FROM nvidia/cuda:11.3.0-runtime-ubuntu20.04

RUN apt-get update
RUN apt-get install -y git
RUN apt-get install -y wget

RUN wget https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86_64.sh
RUN bash Miniconda3-latest-Linux-x86_64.sh -b -p /miniconda
ENV PATH=$PATH:/miniconda/pcondabin:/miniconda/bin

RUN conda update -n base -c defaults conda
RUN conda create -n release python=3.6

SHELL ["conda", "run", "-n", "release", "/bin/bash", "-c"]

COPY environment environment
RUN conda install --yes --file environment/conda.txt
RUN conda install -c rdkit rdkit nox cairo
RUN conda install pytorch=1.10.2 torchvision=0.11.3 -c pytorch -c conda-forge
RUN pip install -r environment/pip.txt

WORKDIR /home

RUN git clone https://github.com/isayev/ReLeaSE.git .

ENTRYPOINT ["conda", "run", "-n", "release", "jupyter", "notebook", "--ip=0.0.0.0", "--port=8888",
"--allow-root", "--NotebookApp.token='', --NotebookApp.password='']
```



The Docker Compose

Servizio con linux con risorse riservate
Nvidia GPU

```
version: "3.8"

services:
  app:
    platform: linux/amd64
    build:
      context: .
      dockerfile: Dockerfile
    ports:
      - ${HTTP_PORT}:8888
    deploy:
      resources:
        reservations:
          devices:
            - driver: nvidia
              capabilities: [[gpu]]
```

The Jupyter Notebook



Jupyter LogP_optimization_demo Last Checkpoint: 24 minuti fa (autosaved)

File Edit View Insert Cell Kernel Widgets Help Not Trusted Python 3

LogP optimization with ReLeaSE algorithm

In this experiment we will optimized parameters of pretrained generative RNN to produce molecules with values of logP within drug-like region according to Lipinsky rule. We use policy gradient algorithm with custom reward function to bias the properties of generated molecules aka Reinforcement Learninf for Structural Evolution (ReLeaSE) as was proposed in [Popova, M., Isayev, O., & Tropsha, A. \(2018\). Deep reinforcement learning for de novo drug design. Science advances, 4\(7\), eaap7885.](#)

Imports

```
In [1]: %env CUDA_VISIBLE_DEVICES=1
env: CUDA_VISIBLE_DEVICES=1

In [2]: %load_ext autoreload
%autoreload 2

In [3]: import sys


In [4]: sys.path.append('./release/')

In [5]: import torch
import torch.nn as nn
from torch.optim.lr_scheduler import ExponentialLR, StepLR
import torch.nn.functional as F
```



04.1

First stage
Setting up the generator





Caricamento dei dati per il generator

```
gen_data_path = './data/chembl_22_clean_1576904_sorted_std_final.smi'
```

```
tokens = ['<', '>', '#', '%', ')', '(', '+', '-', '/', '.', '1', '0', '3', '2', '5', '4', '7',  
          '6', '9', '8', '=', 'A', '@', 'C', 'B', 'F', 'I', 'H', 'O', 'N', 'P', 'S', '[', ']',  
          '\\', 'c', 'e', 'i', 'l', 'o', 'n', 'p', 's', 'r', '\\n']
```

```
gen_data = GeneratorData(training_data_path=gen_data_path, delimiter='\\t',  
                        cols_to_read=[0], keep_header=True, tokens=tokens)
```





function estimate_and_update:

```
def estimate_and_update(generator, predictor, n_to_generate):
    generated = []
    pbar = tqdm(range(n_to_generate))
    for i in pbar:
        pbar.set_description("Generating molecules...")
        generated.append(generator.evaluate(gen_data, predict_len=120)[1:-1])

    sanitized = canonical_smiles(generated, sanitize=False, throw_warning=False)[: -1]
    unique_smiles = list(np.unique(sanitized))[1:]
    smiles, prediction, nan_smiles = predictor.predict(unique_smiles, use_tqdm=True)

    plot_hist(prediction, n_to_generate)

    return smiles, prediction
```





Inizializzazione stack-augmented generative RNN:


```
hidden_size = 1500
stack_width = 1500
stack_depth = 200
layer_type = 'GRU'
lr = 0.001
optimizer_instance = torch.optim.Adadelta

my_generator = StackAugmentedRNN(input_size=gen_data.n_characters, hidden_size=hidden_size,
                                  output_size=gen_data.n_characters, layer_type=layer_type,
                                  n_layers=1, is_bidirectional=False, has_stack=True,
                                  stack_width=stack_width, stack_depth=stack_depth,
                                  use_cuda=use_cuda,
                                  optimizer_instance=optimizer_instance, lr=lr)
```



04.2

First stage
Setting up the predictor





Inizializzazione RNN predictor

```
from rnn_predictor import RNNPredictor
```

```
predictor_tokens = tokens + [' ']
```

```
path_to_params = './checkpoints/logP/model_parameters.pkl'  
path_to_checkpoint = './checkpoints/logP/fold_'
```

```
my_predictor = RNNPredictor(path_to_params, path_to_checkpoint, predictor_tokens)
```






Produzione del unbiased distribution della proprietà

```
smiles_unbiased, prediction_unbiased = estimate_and_update(my_generator,  
                                                           my_predictor,  
                                                           n_to_generate=10000)
```






Output di unbiased
distribution



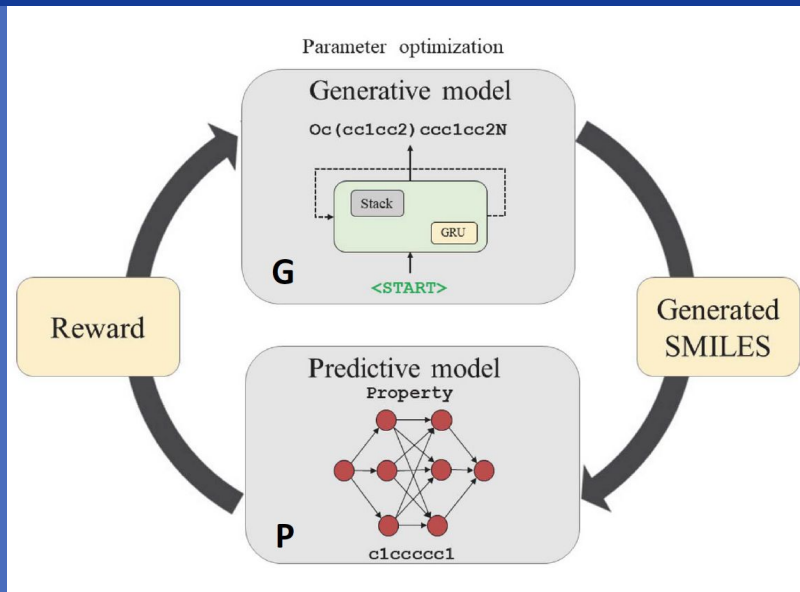
04.3

Second stage
Biasing the distribution
with RL (policy gradient)



Modelli generativi e predittivi in un unico sistema

Reinforcement Learning con funzione di Reward





Creazione di una copia del generator che sarà ottimizzato

```
my_generator_max = StackAugmentedRNN(input_size=gen_data.n_characters,  
                                     hidden_size=hidden_size,  
                                     output_size=gen_data.n_characters,  
                                     layer_type=layer_type,  
                                     n_layers=1, is_bidirectional=False, has_stack=True,  
                                     stack_width=stack_width, stack_depth=stack_depth,  
                                     use_cuda=use_cuda,  
                                     optimizer_instance=optimizer_instance, lr=lr)  
  
my_generator_max.load_model(model_path)
```





La funzione di reward è la seguente:

```
def get_reward_logp(smiles, predictor, invalid_reward=0.0):  
    mol, prop, nan_smiles = predictor.predict([smiles])  
    if len(nan_smiles) == 1:  
        return invalid_reward  
    if (prop[0] >= 1.0) and (prop[0] <= 4.0):  
        return 11.0  
    else:  
        return 1.0
```





Fase del Reinforcement Learning

```
RL_logp = Reinforcement(my_generator_max, my_predictor, get_reward_logp)
```

```
rewards = []  
rl_losses = []
```

```
for i in range(n_iterations):  
    for j in trange(n_policy, desc='Policy gradient...'):  
        cur_reward, cur_loss = RL_logp.policy_gradient(gen_data)  
        rewards.append(simple_moving_average(rewards, cur_reward))  
        rl_losses.append(simple_moving_average(rl_losses, cur_loss))
```

```
plt.plot(rewards)  
plt.xlabel('Training iteration')  
plt.ylabel('Average reward')  
plt.show()  
plt.plot(rl_losses)  
plt.xlabel('Training iteration')  
plt.ylabel('Loss')  
plt.show()
```

```
smiles_cur, prediction_cur = estimate_and_update(RL_logp.generator,  
                                                my_predictor,  
                                                n_to_generate)
```

```
print('Sample trajectories:')  
for sm in smiles_cur[:5]:  
    print(sm)
```






Produzione del biased distribution della proprietà

```
smiles_biased, prediction_biased = estimate_and_update(RL_logp.generator,  
                                                       my_predictor,  
                                                       n_to_generate=10000)
```






The output of the biased
distribution






Unbiased and biased distribution






L'output della biased library sarà qualcosa simile a questo




log P = 1.9681841



log P = 2.9222229




log P = 2.8995206



log P = 0.42920512




log P = 2.354528




log P = 4.693091



log P = 1.6817662



log P = 3.0234919




log P = 2.8313932




log P = 2.7861443




log P = 2.276269



log P = -0.39131445



log P = 2.749243



log P = 3.5084376



log P = 2.3391693



THAT'S ALL

GitHub Repository:



A special thanks to:

- Prof. Rocco Zaccagnino

